





PHÂN CỤM KHÁCH HÀNG SIÊU THỊ BẰNG THUẬT TOÁN K-MEANS

Người thực hiện : Triệu Quang Thịnh và Đào Đức Trọng

Mã sv : 12423034 và 10123329

Giảng viên hướng dẫn : PGS.TS Nguyễn Văn Hậu




MỤC LỤC

1. Giới thiệu đề tài
2. Dataset
3. Khám phá dữ liệu
4. Mô hình áp dụng
5. Demo

GIỚI THIỆU ĐỀ TÀI

GIỚI THIỆU ĐỀ TÀI

Trong kinh doanh bán lẻ, việc hiểu rõ hành vi và nhu cầu của khách hàng là yếu tố then chốt để nâng cao hiệu quả kinh doanh. Với sự gia tăng của dữ liệu khách hàng, các phương pháp phân tích truyền thống trở nên kém hiệu quả. Vì vậy, đề tài phân cụm khách hàng siêu thị bằng thuật toán K-Means được thực hiện nhằm chia khách hàng thành các nhóm có đặc điểm tương đồng. Kết quả phân cụm hỗ trợ siêu thị xây dựng chiến lược marketing phù hợp và tối ưu hóa doanh thu.



Lý do chọn đề tài

- Phân cụm khách hàng giúp siêu thị hiểu rõ hành vi mua sắm, từ đó xây dựng chiến lược marketing và chăm sóc khách hàng hiệu quả hơn.
- Đề tài cho phép áp dụng thuật toán K-Means, một thuật toán học máy phổ biến, dễ hiểu và phù hợp cho bài toán phân tích dữ liệu thực tế.
- Trong bối cảnh dữ liệu khách hàng ngày càng nhiều, phân cụm là phương pháp hiệu quả để khai thác thông tin tiềm ẩn và hỗ trợ ra quyết định kinh doanh.

Mục tiêu của đề tài

- Sử dụng thuật toán K-Means để chia khách hàng thành các nhóm có đặc điểm và hành vi mua sắm tương đồng.
- Từ kết quả phân cụm, hỗ trợ siêu thị xây dựng chiến lược marketing, chăm sóc khách hàng và bán hàng hiệu quả hơn.
- Giúp người thực hiện hiểu rõ quy trình xử lý dữ liệu và ứng dụng thuật toán học máy vào bài toán thực tế.

DATASET

LÝ DO CHỌN DATASET

- Dataset thực tế, dễ tiếp cận: Mall Customer Dataset cung cấp các thông tin quan trọng như tuổi, thu nhập và điểm chi tiêu của khách hàng.
- Phù hợp với bài toán phân cụm: Dữ liệu rõ ràng, không gán nhãn, rất thích hợp áp dụng thuật toán K-Means.
- Ứng dụng cao trong kinh doanh: Kết quả phân cụm hỗ trợ xây dựng chiến lược marketing và chăm sóc khách hàng hiệu quả.
- Thuận lợi cho học tập và minh họa: Dataset phổ biến, dễ trực quan hóa và phù hợp cho đồ án Machine Learning.





TỔNG QUAN BỘ DỮ LIỆU

Bộ dữ liệu bao gồm thông tin của 200 khách hàng, được thu thập nhằm phục vụ cho việc phân tích hành vi tiêu dùng và phân khúc khách hàng. Mỗi quan sát trong dữ liệu tương ứng với một khách hàng, với các thuộc tính nhân khẩu học và hành vi mua sắm cơ bản.

Cấu trúc dữ liệu

Bộ dữ liệu gồm 5 thuộc tính chính:

- Mã khách hàng: Dùng để định danh, không mang ý nghĩa phân tích.
- Giới tính: Gồm nam và nữ, với tỷ lệ tương đối cân bằng (nữ chiếm khoảng 56%, nam khoảng 44%).
- Tuổi: Dao động từ 18 đến 70 tuổi, tập trung chủ yếu ở nhóm tuổi trẻ và trung niên.
- Thu nhập hàng năm: Phân bố từ mức thấp đến cao, phản ánh sự đa dạng về điều kiện kinh tế của khách hàng.
- Điểm chi tiêu (Spending Score): Thể hiện mức độ sẵn sàng chi tiêu của khách hàng, không hoàn toàn tỷ lệ thuận với thu nhập.

Mã khách hàng	Giới tính	Tuổi	Thu nhập hàng n...	Điểm chi tiêu (1-1...
	Nữ giới 56% Nam giới 44%			
1	Nam giới	19	15	39
2	Nam giới	21	15	81
3	Nữ giới	20	16	6
4	Nữ giới	23	16	77
5	Nữ giới	31	17	40
6	Nữ giới	22	17	76
7	Nữ giới	35	18	6
8	Nữ giới	23	18	94
9	Nam giới	64	19	3
10	Nữ giới	30	19	72
11	Nam giới	67	19	14
12	Nữ giới	35	19	99
13	Nữ giới	58	20	15

TỔNG QUAN BỘ DỮ LIỆU

Đặc điểm nổi bật

- Dữ liệu có cấu trúc rõ ràng, không chứa giá trị thiếu.
- Các biến đều mang ý nghĩa thực tế trong phân tích hành vi khách hàng.
- Tồn tại sự khác biệt đáng kể giữa thu nhập và mức độ chi tiêu, cho thấy hành vi mua sắm không chỉ phụ thuộc vào thu nhập.

Khả năng ứng dụng

Bộ dữ liệu đặc biệt phù hợp cho:

- Phân tích khám phá dữ liệu (Exploratory Data Analysis – EDA)
- Các bài toán phân cụm khách hàng (Customer Segmentation) bằng phương pháp học máy không giám sát như K-means.
- Hỗ trợ ra quyết định trong marketing và quản lý khách hàng.


CHI TIẾT CÁC THUỘC TÍNH

Tên thuộc tính	Kiểu dữ liệu	Khoảng / Giá trị	Ý nghĩa	Vai trò trong phân tích & ML
Mã khách hàng (Customer ID)	Số nguyên (Integer)	1 – 200	Định danh duy nhất cho mỗi khách hàng	Không sử dụng trong mô hình học máy
Giới tính (Gender)	Danh mục (Categorical)	Nam, Nữ	Thông tin nhân khẩu học cơ bản	Phân tích hành vi theo giới; cần mã hóa khi dùng cho ML
Tuổi (Age)	Số (Numerical – Continuous)	18 – 70	Độ tuổi của khách hàng	Phân tích xu hướng tiêu dùng theo độ tuổi; dùng cho phân cụm
Thu nhập hàng năm (Annual Income)	Số (Numerical – Continuous)	15 – 137 (nghìn USD/năm)	Phản ánh khả năng tài chính	Biến quan trọng trong phân khúc khách hàng
Điểm chi tiêu (Spending Score)	Số (Numerical – Ordinal)	1 – 99	Mức độ sẵn sàng chi tiêu	Biến chính để đánh giá hành vi mua sắm và phân cụm

KHÁM PHÁ DỮ LIỆU


BIỂU ĐỒ SỐ LƯỢNG KHÁCH HÀNG THEO GIỚI TÍNH

- Biến: Giới tính (Female, Male) và Số lượng khách hàng tương ứng.
- Không có lỗi: Độ cao cột thể hiện số lượng khách hàng cho từng giới tính.
- Kết quả quan sát:
 - Female có số lượng lớn hơn Male.
 - Female xấp xỉ hơn 100 khách hàng; Male khoảng 90 khách.



BIỂU ĐỒ PHÂN BỐ NHÓM TUỔI KHÁCH HÀNG

- Biến phân loại: Nhóm tuổi (dưới 20; 20-30; 30-40; 40-50; 50-60; trên 60).
- Biến đích: Số lượng khách hàng tương ứng với mỗi nhóm tuổi.



MÔ HÌNH ÁP DỤNG

K-MEANS

K-Means là một thuật toán học không giám sát (Unsupervised Learning) dùng để phân cụm dữ liệu (clustering).


👉 Mục tiêu:

Chia dữ liệu thành K nhóm (K cụm) sao cho:

- Các điểm trong cùng một cụm thì giống nhau
- Các điểm khác cụm thì khác nhau

📌 Quan trọng:

- Không có nhãn sẵn (khác với classification)
- Máy tự tìm cấu trúc trong dữ liệu



Quy trình áp dụng


- Bước 1: Chọn số cụm K
- Bước 2: Khởi tạo centroids
- Bước 3: Gán điểm dữ liệu
- Bước 4: Cập nhật centroids
- Bước 5: Lặp cho đến khi không đổi

ƯU ĐIỂM

- K-Means dựa trên việc tính khoảng cách giữa các điểm dữ liệu và tâm cụm, nên rất trực quan và dễ triển khai.
- Thuật toán có độ phức tạp thấp, phù hợp với các tập dữ liệu lớn trong thực tế.
- K-Means được hỗ trợ sẵn trong nhiều thư viện học máy như Scikit-learn, giúp tiết kiệm thời gian phát triển.
- Khi các cụm có dạng hình cầu và phân bố tương đối đều, K-Means cho kết quả phân cụm tốt.
- Kết quả phân cụm có thể dễ dàng biểu diễn bằng biểu đồ 2D hoặc 3D để phân tích.

NHƯỢC ĐIỂM

- Việc chọn K không đơn giản và có thể ảnh hưởng lớn đến chất lượng kết quả phân cụm.
- Nếu chọn tâm cụm ban đầu không tốt, thuật toán có thể cho kết quả không tối ưu.
- K-Means không đảm bảo tìm được nghiệm tối ưu toàn cục cho bài toán phân cụm.
- Các điểm dữ liệu bất thường có thể làm lệch vị trí tâm cụm, dẫn đến phân cụm sai.
- K-Means hoạt động kém khi các cụm không có dạng hình cầu hoặc kích thước không đồng đều.




ELBOW

Elbow là phương pháp giúp xác định số cụm K phù hợp bằng cách quan sát mức độ giảm của tổng sai số trong cụm (WCSS – Within-Cluster Sum of Squares) khi tăng K.

Ý tưởng chính:

- 👉 Khi tăng K, WCSS sẽ giảm
- 👉 Đến một điểm nào đó, tốc độ giảm chậm lại rõ rệt
- 👉 Điểm đó tạo thành hình giống khuỷu tay (Elbow) → chọn K tại đó



WCSS (Within-Cluster Sum of Squares)

Dùng để:

- Chọn số cụm K (Elbow Method)

Ý nghĩa:

- Đo độ “chặt” của các cụm
- WCSS càng nhỏ $\rightarrow$ cụm càng tốt

Công thức:

$$WCSS = \sum_{i=1}^k \sum_{x \in C_i} ||x - \mu_i||^2$$

ƯU ĐIỂM

- Elbow dựa trên việc quan sát đồ thị WCSS theo số cụm K, nên rất trực quan và dễ áp dụng.
- Phương pháp này phù hợp với bài toán học không giám sát như K-Means.
- Elbow giúp người dùng có cơ sở hợp lý để lựa chọn K thay vì chọn ngẫu nhiên.
- Elbow thường được dùng trong các bài toán phân cụm và dễ giải thích trong thuyết trình.
- Phương pháp này hoạt động hiệu quả khi kết hợp trực tiếp với thuật toán K-Means.

NHƯỢC ĐIỂM

- Việc xác định “điểm khuỷu tay” phụ thuộc vào cách nhìn của người phân tích.
- Với một số tập dữ liệu, đồ thị WCSS giảm đều và khó xác định điểm gãy.
- Elbow chỉ mang tính gợi ý, không phải tiêu chí toán học chặt chẽ.
- Dữ liệu có nhiều hoặc phân bố phức tạp làm đồ thị Elbow khó phân tích.
- Elbow thường chỉ áp dụng hiệu quả cho K-Means và các biến thể tương tự.

Phương pháp đánh giá

Silhouette Score là chỉ số đánh giá nội tại trong bài toán phân cụm, dùng để đo:

- Mức độ chặt chẽ trong cùng cụm
- Mức độ tách biệt giữa các cụm

Chỉ số này không cần nhãn dữ liệu, rất phù hợp cho các thuật toán học không giám sát như K-Means.

Công thức:

$$s = \frac{b - a}{\max(a, b)}$$

- a: khoảng cách trung bình trong cùng cụm
- b: khoảng cách tới cụm gần nhất khác

Thang đo: [-1, 1]

Davies–Bouldin Index (DBI) là một chỉ số nội bộ (internal metric) dùng để đánh giá chất lượng phân cụm, dựa trên:

- Độ chặt trong từng cụm
- Độ tách biệt giữa các cụm

DBI càng nhỏ thì kết quả phân cụm càng tốt.

Công thức:

$$DBI = \frac{1}{K} \sum_{i=1}^K \max_{j \neq i} \left(\frac{S_i + S_j}{M_{ij}} \right)$$

- S_i : Khoảng cách trung bình từ các điểm trong cụm i đến tâm cụm μ_i
- M_{ij} : Khoảng cách giữa hai tâm cụm


K	Silhouette	Davies-Bouldin Index
4	0.4943	0.6975
5	0.5547	0.5722
6	0.5138	0.6239
7	0.5020	0.6925

Với k=5 thì:

Silhouette Score cao nhất


Davies-Bouldin Index thấp nhất

=>k=5 tối ưu nhất



Phân cụm khách hàng

Màu	Nhóm khách hàng	Đặc điểm	Chiến lược
Tím	Thu nhập thấp – Chi tiêu thấp	Ít mua	Không ưu tiên
Vàng	Thu nhập thấp – Chi tiêu cao	Nhạy khuyến mãi	Giảm giá
Xanh dương	Trung bình	Ổn định	Duy trì
Đỏ	Thu nhập cao – Chi tiêu thấp	Tiềm năng	Kích thích chi tiêu
Xanh lá	Thu nhập cao – Chi tiêu cao	VIP	Chăm sóc đặc biệt



DEMO

Bạn có câu hỏi nào không?

Hãy gửi cho chúng tôi! Hy vọng bạn đã học được thêm điều mới mẻ.

